

Un agente que lee informes 10-K y cita de dónde saca cada dato

Un 10-K es el informe anual que toda empresa cotizada en EE. UU. presenta al regulador: cientos de páginas de riesgos, comentario de la dirección y cuentas auditadas. La pregunta de la práctica es si un modelo de lenguaje puede responder sobre él sin inventarse nada, diciendo siempre de qué párrafo o de qué dato oficial sale cada cifra.

GRUPO 3

Óscar Romero Quincoces

Daniel García López

Fernando Dapena Tauste

Antes de preguntar nada, el corpus se verifica byte a byte

48

secciones de informe
6 empresas × 2 ejercicios
× ítems 1A, 7, 7A y 8

1.749

fragmentos de unas 500
palabras, buscables por
significado, no por texto

135

hechos XBRL: las cifras que
la empresa declara etiquetadas.
La única fuente de números

4

huellas verificadas: si cambia
un byte, cambia la huella.
Una cruza fragmentos e índice

649.119

tokens: trozos de palabra,
lo que el modelo paga por
leer. Leerlo entero no cabe

TRES VISTAS DEL MISMO TEXTO


	Ejercicio 2024				Ejercicio 2025			
	1A	7	7A	8	1A	7	7A	8
NVDA								
MSFT								
AAPL								
GOOGL								
META								
AMZN								

Sección íntegra, fragmento citable e índice vectorial. 1A riesgos ·
7 dirección · 7A mercado · 8 cuentas

LO QUE ENCONTRAMOS AL MIRAR LOS DATOS

HALLAZGO	CONSECUENCIA DE DISEÑO
La sección más larga tiene 34.751 tokens	Buscar el fragmento primero; la sección entera, último recurso
21 casillas vacías: 10 son huecos reales y 11, el mismo ingreso con otra etiqueta	Probar los dos conceptos antes de decir que no existe
El 63 % de los fragmentos de las cuentas contienen tabla	Una cifra de tabla partida se confirma en XBRL, nunca en el texto
Los cierres fiscales caen en cuatro meses distintos	Se pregunta por ejercicio, jamás por año natural

La firma es el contrato, pero lo que decide qué herramienta se usa es su descripción



Leer entera la sección más larga cuesta **34.751 tokens**: lo mismo que **868 consultas** a los datos oficiales. Por eso `read_section` se paginó a 6.000 caracteres — esa sección exige 33 llamadas — y solo se justifica cuando la búsqueda ya ha fallado.

LAS FIRMAS NO SE TOCAN


```
list_available()
get_xbrl_fact(ticker, fiscal_year, concept)
search_filings(query, ticker, fiscal_year,
               item, k=5)
read_section(ticker, fiscal_year, item)
```

1.659

caracteres suman las cuatro descripciones: es todo lo que el modelo sabe de sus herramientas

- Las cuatro llevan «**cuándo usarla**» y «**cuándo NO**», y las equivalencias del español al vocabulario XBRL viven dentro de la descripción, no en un manual.
- El sistema final cambia **solo la descripción** de `search_filings` y reutiliza su esquema intacto: cambia el comportamiento sin romper el contrato.

El agente trabaja por vueltas: **decide, pide, lee y vuelve a decidir**



La flecha curva es el bucle: mientras falte evidencia, otra vuelta. Lo cierran un máximo de vueltas, un plazo duro por pregunta y un hilo de conversación nuevo en cada una, para que no arrastre la anterior.

EL FORMULARIO: OCHO CAMPOS QUE NO SE PUEDEN QUITAR

respuesta

cifra

unidad

ticker

ejercicio


fuente

cita

chunk_id

- fuente** solo admite **xbrl, texto, ambas o ninguna**. Si el dato no está, se dice; no se estima.
- Añadimos cuatro campos opcionales para las comparativas. Ninguno se quita ni se renombra: es contrato.

DÓNDE VAN LAS LLAMADAS, ANTES Y DESPUÉS



El sistema de partida se congela a propósito: un modelo, temperatura 0, las cuatro herramientas originales y sin controles. Así, cualquier mejora posterior es del agente y no del proveedor.

Veinte preguntas propias: cada cifra sale de XBRL y cada cita se ancla a una frase literal


FAMILIA	N.º	QUÉ EXIGE	EJEMPLO REAL DEL EXAMEN
Numérica	7	Cifra exacta de la fuente autorizada	«¿Gasto en I+D de MSFT en el ejercicio 2025?» → 32.488 millones USD
Extractiva	6	Localizar y citar el pasaje	«¿Qué dice la dirección de Amazon sobre AWS?» → ancla: «AWS sales increased 20% in 2025...»
Comparativa	7	Dos consultas y una explicación	«¿Cómo evolucionó el flujo de caja de AMZN?» → 115.877 → 139.514 millones, +20,4 %
Hueco	6	Fichero aparte: el dato no debe existir	«¿Margen bruto de AMZN en 2025?» → no está en el corpus, y no se estima

EL ANCLA ES LA FRASE, NO EL FRAGMENTO

Un identificador de fragmento caduca en cuanto se vuelve a trocear el corpus; la frase literal no. El validador exige presencia textual, posiciones exactas y un máximo de 40 palabras. Nuestras trece anclas van de 11 a 39.

La trampa que metimos a propósito. El beneficio por acción de NVIDIA cae de 12,05 a 2,97 dólares: un -75 %. Pero el beneficio neto subió de 29.760 a 72.880 millones. El desdoblamiento 10:1 de 2024 reexpresa la serie hacia atrás. La cifra sola engaña; hay que leer el texto para no concluir lo contrario de lo que pasó.

El sistema de partida acertaba las cifras y **no sostenía ni una sola cita**




TRES COMPROBACIONES DETERMINISTAS Y UN JUEZ, Y SE EXIGEN A LA VEZ

- **La cita.** Existe: está literal en la sección. Vista: salió de una herramienta *en esa misma ejecución*, no de memoria. Respalda lo que la respuesta afirma.
- **La cifra.** Contra el dato publicado, no contra el texto. Tolerancia: **0,5 %** sobre el valor XBRL en dólares y **0,005** absoluto en beneficio por acción.
- **El camino.** Qué herramienta pidió. La caja de Meta en 2024 y su I+D difieren un 0,04 %: ninguna tolerancia numérica los distingue; el camino sí.
- **Y un cuarto criterio, que no es determinista:** un segundo modelo hace de juez y decide si la respuesta significa lo mismo que la esperada. Es el que dicta las siete derrotas del sistema final. Cambiarlo por otro modelo dio 20 veredictos idénticos.

ESTO VA EN NUESTRA CONTRA

El diagnóstico de la primera medición no era el que esperábamos. Las 20 preguntas usaron la herramienta que tocaba y las 14 cifras aplicables eran correctas. En las 13 que obligan a citar, **el fragmento existía y el agente lo había visto las trece veces**. Ninguna respaldaba lo que la respuesta afirmaba.


Un cambio cada vez: el buscador pasa de encontrar **2 de 13 párrafos a 5 de 13**



- **El filtro por metadatos es el cambio que más rinde.** Restringir a empresa, ejercicio y sección duplica el acierto y multiplica por ocho lo alto que sale el párrafo bueno en la lista. Deja entre 2 y 75 fragmentos de los 1.749.
- **BM25** —coincidencia de palabras, frente a la densa, que compara significados— añade uno al fusionarse con ella. Por su cuenta se queda en 2 de 13: la pregunta va en español y el informe en inglés.
- **La reescritura mueve seis preguntas y no gana ninguna**, y su efecto depende por completo del modelo: con el que entregamos cae a 0 de 13. Por eso la búsqueda final no reescribe: es determinista.

El límite no es el método. Dos preguntas no aparecen en el top-20 de ninguno de los dos buscadores: el máximo alcanzable es 11, no 13. El ancla siempre cae dentro del filtro; lo que falla es la ordenación.

La vigilancia de las cifras la hace código determinista, sin un modelo de por medio



- **Techo de gasto por pregunta.** Ocho llamadas a herramienta, una sola a `read_section` y diez al modelo. Acota el peor caso, no la mediana: en la ejecución entregada el máximo real fueron cinco, y el tope no llegó a activarse.
- **La cita se señala, no se copia.** El modelo ve un número delante de cada frase recuperada y responde con el número; el sistema pega después la frase y su fragmento, literales. Las trece citas salieron así.
- **Si el desajuste persiste, la cifra se retira** y la fuente pasa a «ninguna». Nunca se inventa.

13 de 13


citas resueltas por frase numerada en la ejecución entregada; cero reintentos y cero problemas sin resolver

ESTO VA EN NUESTRA CONTRA

El verificador de cifras nunca llegó a saltar. En las ocho ejecuciones del sistema final no devolvió un solo desajuste, porque ninguna cifra vino mal. Lo defendemos igual: es determinista, no cuesta una llamada, y es lo que permite derivar la fuente de la evidencia en vez de creerle al modelo.

De 7 a 13 aciertos sobre 20 y una cita verificada en cada respuesta, a cambio de un 19 % más de coste


SISTEMA	NUM. (7)	EXTR. (6)	COMP. (7)	HUECOS (6)	ACIERTO GLOBAL	CITA VÁLIDA	RECALL@5 AISLADO	RECALL EN EL AGENTE	COSTE USD/PREG.	LATENCIA MEDIA	TOKENS /PREG.	LLAMADAS /PREG.
De partida	7/7	0/6	0/7	6/6	35 %	0/13	2/13	11/13	0,0144 ★	15,0 s ★	19.082	2,80
Final	7/7	2/6 ★	4/7 ★	6/6	65 % ★	13/13 ★	5/13 ★	11/13	0,0171	18,6 s	12.992 ★	2,15 ★



De dónde sale la ganancia. Las numéricas ya estaban resueltas en las dos: vienen de XBRL. Todo el margen estaba en el texto. Y el recall dentro del agente **empata en 11/13**: las dos veían el párrafo correcto; la de partida no lo usaba.

ESTO VA EN NUESTRA CONTRA
Sube el coste un 19 % y la latencia un 24 %, aunque lea un 32 % menos: escribe más del doble, y la salida es el token caro. Y **tener cita válida no basta**: las 13 preguntas que obligan a citar traen cita buena y solo 6 son acierto.

Pagar por el proveedor compró fiabilidad, no acierto



CONFIRMADO

Con el proveedor gratuito, **9 de las 20 preguntas agotaron el plazo** de 300 s y nunca devolvieron respuesta; la mediana fue de **264 s**. Con el de pago, en las dos ejecuciones del sistema final: **ninguna perdida** y **21,6 s** de mediana.

HIPÓTESIS REFUTADA

La hipótesis era que el de pago acertaría más. Dos repeticiones con el mismo código, las mismas preguntas y temperatura 0 dieron **15 y 12 aciertos de 20**: tres veredictos cambiaron sin cambiar nada. La ejecución entregada, 13 de 20, cae en medio de ese rango. Con esa variación no se afirma, **y no lo afirmamos**.

ERROR QUE COMETIMOS

La primera versión medía la ronda gratuita con un código anterior: cambiaban a la vez modelo, búsqueda y prompt. **Tres variables en lugar de una**. Se rehízo entera. Declarar «misma configuración» no bastaba: la comparación contaminada también lo declaraba. Ahora se le pregunta a git si `src/` cambió.

En las ciegas acierta 8 de 10; las dos que falla son comparativas

QUÉ SE COMPARA	EXAMEN PROPIO (20, REFERENCIA)	CIEGAS (10, EL DÍA 24)
Acierto global (micro)	13/20 · 65 %	8/10 · 80 %
Acierto medio por familia (macro)	0,63	0,88
Numéricas	7/7	1/1
Extractivas	2/6	3/3
Comparativas	4/7	2/4
Huecos (debe abstenerse)	—	2/2
Cifras contra XBRL	7/7	5/5
Citas existentes y vistas	13/13	7/7
Abstenciones indebidas	0	0
Llamadas por pregunta	2,15	2,00
Latencia mediana	17,5 s	15,4 s
Tokens por pregunta	12.992	11.049
Coste por pregunta	0,017 USD	0,015 USD

LAS DOS QUE FALLA

- **ho-007**: las cifras cuadran con XBRL, pero la cita que aporta **no respalda** la respuesta.
- **ho-009**: cifras y cita correctas, pero el juez da la **respuesta por incorrecta**.
- El resto, limpio: **cero errores** de ejecución, cero fallos del juez y las diez encuentran el documento correcto.

Mismo modelo en las dos columnas (gemini-3.8-flash, temperatura 0): el delta mide el agente, no el proveedor. Con diez preguntas, cada una mueve **10 puntos**: el 80 % no demuestra que generalice mejor, pero sí que **no se degrada** fuera del examen con el que iteramos. Coste total **0,15 USD**.

Lo que probamos que no funcionó, y lo que nos llevamos

LO QUE PROBAMOS	QUÉ PASÓ
Dar reglas al modelo para elegir qué frase citar	Empeoran las tres variantes
Reescribir la consulta con el modelo	Cero en neto, y depende del modelo
Filtrar en local antes de llamar al juez	No bloquea ningún caso
Bajar el esfuerzo de razonamiento del modelo	El modelo no lo respeta
Ampliar el plazo por pregunta de 300 a 420 s	No recupera ninguna
Cambiar el modelo que hace de juez	20 de 20 veredictos idénticos
Pagar un modelo mejor para acertar más	Refutado, página 9

Un arreglo razonable que no mueve la métrica es un resultado. Los siete quedan registrados con su fecha, su configuración y la métrica antes y después, para no volver a probarlos.

13/20

frente a 7 de 20 del sistema de partida, con un 23 % menos de llamadas y un tercio menos de texto leído

El sistema de partida **encontraba** la frase correcta y aun así suspendía las trece. Lo que arreglamos no fue buscar mejor: fue no afirmar nada que la cita no sostenga.

El techo que queda está localizado: siete preguntas en las que la cita, la cifra y el camino son correctos y el juez no da la respuesta por equivalente. El camino exacto no ha devuelto nunca una cifra equivocada en las trece ejecuciones del examen propio.