

# Un agente que lee informes 10-K y cita de dónde saca cada dato

---

## GRUPO 3

Óscar Romero Quincoces

Daniel García López

Fernando Dapena Tauste

# Un informe anual tiene cientos de páginas: el reto es no leerlas todas

6

empresas  
NVDA, MSFT, AAPL,  
GOOGL, META, AMZN

2

ejercicios fiscales  
2024 y 2025

48

secciones de informe  
riesgos, gestión,  
mercado y cuentas

1.749

fragmentos de texto  
la unidad que se cita

135

cifras oficiales  
tal y como las  
reportó la empresa

650.000

tokens en total  
leerlo entero  
no es viable

LO QUE HAY DENTRO DEL CORPUS

|       | Ejercicio 2024 |   |    |   | Ejercicio 2025 |   |    |   |
|-------|----------------|---|----|---|----------------|---|----|---|
|       | 1A             | 7 | 7A | 8 | 1A             | 7 | 7A | 8 |
| NVDA  |                |   |    |   |                |   |    |   |
| MSFT  |                |   |    |   |                |   |    |   |
| AAPL  |                |   |    |   |                |   |    |   |
| GOOGL |                |   |    |   |                |   |    |   |
| META  |                |   |    |   |                |   |    |   |
| AMZN  |                |   |    |   |                |   |    |   |

1A riesgos · 7 análisis de la dirección · 7A riesgo de mercado · 8 estados financieros


LO QUE SE LE PIDE AL AGENTE

- **Responder con un dato concreto**, no con un resumen: una cifra, una frase literal del informe o un “esto no está en el corpus”.
- **Decir de dónde sale**: la cita textual y el identificador del fragmento, para que cualquiera pueda ir a comprobarlo.
- **Elegir bien la herramienta**. Acertar el dato por el camino equivocado cuenta como fallo, y hay un evaluador que lo detecta.
- **Y hacerlo por céntimos**. El coste y el tiempo son columnas de la tabla que se evalúa, no una nota al pie.

LAS TRAMPAS QUE TRAE EL CORPUS

- El **ejercicio fiscal no es el año natural**: los seis cierran en cuatro meses distintos. El FY2025 de NVIDIA cerró en enero de 2025.
- El **ingreso no tiene una etiqueta única**: NVIDIA usa Revenues y Microsoft RevenueFrom... . Hay que mirar el fichero, no razonar por analogía.
- **Hay huecos de verdad**: Amazon no publica margen bruto. Preguntarlo es legítimo y la respuesta correcta es decir que no está.

# Hay cuatro formas de buscar un dato y entre ellas hay un factor 868



# 868x

lo que separa preguntar el dato exacto de leerse la sección entera

## LAS FIRMAS SON CONTRATO

```
list_available()
get_xbrl_fact(ticker, fiscal_year, concept)
search_filings(query, ticker, fiscal_year,
               item, k)
read_section(ticker, fiscal_year, item)
```

- Lo único que ve el modelo para decidir es la **descripción** de cada herramienta. Nunca ve el código, así que las reescribimos tantas veces como él.
- Nombres y parámetros no se tocan: el día 24 las preguntas se ejecutan contra estas firmas exactas.

Lo que cuesta elegir mal, medido en nuestra propia ejecución: `g3-001` («beneficio bruto de NVIDIA en 2024») se resuelve con **una** llamada a `get_xbrl_fact`, en **2,5 s** y por **0,0024 USD**. `g3-009` necesitó **ocho** búsquedas encadenadas, **82 s** y **0,102 USD** — 43 veces más cara — y aun así la fallamos.

# El agente decide, mira lo que le devuelven y vuelve a decidir



La flecha curva es el bucle: el agente puede volver a buscar en otra sección, o con otra herramienta, antes de dar la respuesta por buena. El tope de ocho llamadas es lo que impide que ese bucle se eternice.

## LOS OCHO CAMPOS QUE DEVUELVE SIEMPRE

respuesta

cifra

unidad

ticker

ejercicio

fuente

cita

chunk\_id

- **Formato fijo, nunca prosa suelta.** Es lo que permite corregir veinte preguntas de forma automática y ejecutar las diez ciegas en cuatro minutos.
- **fuente admite «ninguna».** Si el dato no está en el corpus, el agente lo dice en lugar de estimarlo.
- **cita y chunk\_id son la trazabilidad:** la frase literal y la dirección exacta donde comprobarla.

## LOS CONTROLES, Y LO QUE HICIERON DE VERDAD

| CONTROL          |                                                          | QUÉ HACE     | VECES |
|------------------|----------------------------------------------------------|--------------|-------|
| Tope de llamadas | 8 por pregunta, y solo 1 puede ser                       | read_section | 0     |
| Cita por frase   | Reancla la cita a la frase numerada que el modelo señaló |              | 12    |
| Verificador XBRL | Contrasta cada cifra y devuelve el desajuste al modelo   |              | 0     |
| Rescate          | Reconstruye la respuesta si el proveedor falla           |              | 1     |

### ESTO VA EN NUESTRA CONTRA

El verificador de cifras **nunca llegó a saltar** en trece ejecuciones: ninguna cifra vino mal, así que no ha sumado ni un acierto. Lo defendemos igual — sin él las numéricas están bien *porque sí*; con él, están bien *y consta*.

# Tres cambios sobre el punto de partida, **cada uno medido por separado**

## 1 · BÚSQUEDA

Cómo encuentra los fragmentos de texto candidatos antes de leerlos.

2 → 5

frases encontradas, de 13

- Filtro por empresa, año y sección cuando la pregunta los nombra
- Búsqueda por palabras (BM25) combinada con la búsqueda por significado
- La consulta va en inglés, el idioma del corpus

## 2 · ENRUTADO

Cómo decide qué herramienta usar y cuántas veces llamarla.

3,3 → 2,2

llamadas por pregunta

- En una comparativa, las tres consultas salen en un solo mensaje en lugar de tres idas y vueltas
- El universo del corpus va en las instrucciones: si preguntan por una empresa que no está, ni lo intenta

## 3 · CITAS Y CONTROLES

Cómo se respalda la respuesta y qué se comprueba antes de darla por buena.

0 → 12

citas válidas, de 13

- **El modelo no copia la cita: la señala con el dedo.** Cada frase que devuelve la búsqueda va numerada y él responde con el número; el sistema pega la frase literal y su fragmento
- Tope de llamadas y verificación de toda cifra antes de responder

La búsqueda es una herramienta más dentro del agente, no la arquitectura entera. Así que no buscamos más veces: **buscamos menos y con el filtro puesto.**

En el código no hay ni una regla por pregunta ni un identificador de nuestro examen. Las diez preguntas del día 24 serán distintas y el sistema tiene que comportarse igual.


# El sistema final **acierta casi el doble** con **un tercio menos de trabajo**

| SISTEMA          | NUM.<br>(7) | EXTR.<br>(6) | COMP.<br>(7) | HUECOS<br>(6) | ACIERTO<br>GLOBAL | CITA<br>VÁLIDA | RECALL@5<br>AISLADO | RECALL EN<br>EL AGENTE | COSTE<br>USD/PREG. | LATENCIA<br>MEDIA | TOKENS<br>/PREG. | LLAMADAS<br>/PREG. |
|------------------|-------------|--------------|--------------|---------------|-------------------|----------------|---------------------|------------------------|--------------------|-------------------|------------------|--------------------|
| Punto de partida | 7/7         | 0/6          | 0/7          | 6/6           | 35 %              | 0/13           | 2/13                | 11/13                  | 0,0178 ★           | 18,7 s ★          | 31.437           | 3,30               |
| Sistema final    | 7/7         | 2/6 ★        | 4/7 ★        | 6/6           | 65 % ★            | 12/13 ★        | 5/13 ★              | 13/13 ★                | 0,0184             | 22,2 s            | 16.021 ★         | 2,20 ★             |



LO QUE HAY QUE LEER AQUÍ

- **13 de 20 frente a 7 de 20.** Los 6 huecos se puntúan aparte, y por eso la fila no suma 26.
- **Tener cita válida no basta.** De las 13 preguntas que obligan a citar, 12 traen una cita buena y solo 6 son acierto: en las otras 6 el juez no da la respuesta por equivalente a la esperada.
- **Y sale casi gratis.** El coste sube un 3 % y tarda 3,5 s más: es lo que vale comprobar las cifras antes de responder.



# El sistema de partida **sí encontraba la frase**. Fallaba después

|                     | NUMÉRICAS |     |     |     |     |     |     | EXTRACTIVAS |     |     |     |     |     |     | COMPARATIVAS |     |     |     |     |     |
|---------------------|-----------|-----|-----|-----|-----|-----|-----|-------------|-----|-----|-----|-----|-----|-----|--------------|-----|-----|-----|-----|-----|
| Punto de partida    | SÍ        | SÍ  | SÍ  | SÍ  | SÍ  | SÍ  | SÍ  | NO          | NO  | NO  | NO  | NO  | NO  | NO  | NO           | NO  | NO  | NO  | NO  | NO  |
| Sistema final       | SÍ        | SÍ  | SÍ  | SÍ  | SÍ  | SÍ  | SÍ  | SÍ          | NO  | NO  | SÍ  | NO  | NO  | SÍ  | NO           | SÍ  | SÍ  | ERR | SÍ  | NO  |
| 6 preguntas ganadas | 001       | 002 | 003 | 004 | 005 | 006 | 007 | 008         | 009 | 010 | 011 | 012 | 013 | 014 | 015          | 016 | 017 | 018 | 019 | 020 |

ERR = el proveedor no contestó; cuenta como fallo

|                  | el fragmento<br>existe | el agente<br>lo vio  | la frase respalda<br>lo que afirma |
|------------------|------------------------|----------------------|------------------------------------|
| Punto de partida | <div></div><br>13/13   | <div></div><br>13/13 | <div></div><br>0/13                |
| Sistema final    | <div></div><br>12/13   | <div></div><br>12/13 | <div></div><br>12/13               |

aquí se caía todo

De las 20 preguntas, **13 obligan a citar**. El de partida superaba las dos primeras etapas **las trece veces**: en 11 el identificador del fragmento era correcto y en 5 su cita coincidía palabra por palabra con la frase que esperábamos.

ESTO VA EN NUESTRA CONTRA

Fallaba por lo contrario de lo que parece: **decía más de lo que su cita sostenía**. En g3-011 citó bien y luego añadió «alcanzando 128.725 millones», que **no está en la frase citada**. Una sola frase sin respaldo tumba la pregunta entera.

# Lo que de verdad hace el agente, sin resumir ni un paso

LA PREGUNTA

¿Cómo evolucionaron los ingresos totales de MSFT entre los ejercicios fiscales 2024 y 2025, y qué explica la dirección al respecto?

3 LLAMADAS,  
UN SOLO TURNO

```
get_xbrl_fact(MSFT, 2025, RevenueFromContractWithCustomerExcludingAssessedTax)
get_xbrl_fact(MSFT, 2024, ...)
search_filings("revenue increased driven by", MSFT, 2025)
```

LA CITA

“Revenue increased \$36.6 billion or 15% with growth across each of our segments.”  
elegida por número de frase, no copiada · chunk\_id MSFT-2025-7-0007

LA RESPUESTA

«Los ingresos aumentaron 36.600 millones de dólares o un 15 % con crecimiento en cada uno de los segmentos.»  
cifra 281.724.000.000 · cifra\_base 245.122.000.000 · fuente ambas

VEREDICTO

cita ✓ cifra ✓ camino ✓ equivalencia ✓ — acierto. 24,2 s y 0,018 USD.

**Lo que no hizo, y también cuenta:** ni una llamada a read\_section, ni una segunda búsqueda, ni un solo reintento. El evaluador de trayectoria comprueba justo eso: que el número venga de get\_xbrl\_fact y no leído de la prosa de una tabla.


POR QUÉ ESTA PREGUNTA LO RESUME TODO

- Necesita **dos cifras de un fichero** y una **explicación de la prosa**: las tres cosas, por menos de dos céntimos.
- Las tres llamadas salen **a la vez**. Por eso 2,2 llamadas por pregunta y no 3,3.
- El concepto XBRL del ingreso **no es universal**: NVIDIA usa Revenues y Microsoft RevenueFromContractWithCustomer... . El agente lo mira en el fichero, nunca razona por analogía con otra empresa.

ESTO VA EN NUESTRA CONTRA

La misma pregunta en el sistema de partida: citó **cuatro frases seguidas** y devolvió chunk\_id a nulo. Cita sin dirección, imposible de verificar, y suspende con la cifra correcta.

# El filtro duplicó el acierto; la reescritura no movió nada



Cada barra: en cuántas de las 13 preguntas con frase de referencia aparece esa frase entre los cinco primeros resultados. Se mide el buscador solo, sin agente.

| PASO                                 | ACIERTO@5 | ACIERTO@10 | MRR@10 | TIEMPO |
|--------------------------------------|-----------|------------|--------|--------|
| Búsqueda densa (punto de partida)    | 2/13      | 2/13       | 0,04   | 80 ms  |
| + filtro de empresa, año y sección   | 4/13      | 7/13       | 0,30   | 86 ms  |
| + BM25 combinado con la densa        | 5/13      | 6/13       | 0,24   | 82 ms  |
| + reescritura de la consulta         | 5/13      | 7/13       | 0,26   | 196 ms |
| Solo BM25 (diagnóstico)              | 2/13      | 7/13       | 0,14   | 1 ms   |
| Reescritura con la respuesta (techo) | 6/13      | 10/13      | 0,38   | 197 ms |

Las dos últimas filas nadie nos las pidió. BM25 a solas da lo mismo que la densa a solas: lo que funciona es combinarlas. Y reescribir *con la respuesta delante* solo llega a 6/13, así que el problema no estaba en cómo se formulaba la consulta.

# Cuatro caminos, y el agente elige solo: 7 + 6 + 6 preguntas y 6 huecos

CAMINO EXACTO

7

Piden una cifra

Una llamada a `get_xbrl_fact` y se responde sin leer una línea de texto. **7 de 7 en las cuatro ejecuciones completas**, con los tres modelos que probamos.

CAMINO DIFUSO

6

Piden qué dice el informe

`search_filings` con filtro de empresa, año y sección, y se cita la frase tal cual. Aquí estaba todo el margen, y aquí siguen nuestros siete fallos.

LAS DOS COSAS

6

Comparan dos ejercicios

Dos cifras y una frase, pedidas **en un solo mensaje**. Es el cambio que baja las llamadas de 3,3 a 2,2.


SIN RESPUESTA

6

El dato no existe

Amazon no publica margen bruto. **6 de 6** resueltos y **cero** veces dijo «no está» teniendo el dato delante.

EN QUÉ SE GASTAN LAS LLAMADAS, HERRAMIENTA A HERRAMIENTA



**Dos caminos distintos para un hueco, los dos correctos.** En `g3-h001` el agente pregunta por el margen bruto de Amazon, la herramienta responde que no está reportado y él devuelve `fuelle: ninguna` sin cifra. En `g3-h006` ni lo intenta: llama a `list_available`, ve que Tesla no está en el corpus y lo dice.

ESTO VA EN NUESTRA CONTRA


Los **6/6 huecos los consigue también el sistema de partida, sin ningún control**. La mejora en huecos la aporta el modelo, no nuestra regla. El control se justifica por otra vía: impide afirmar una cifra sin contrastarla.

LO QUE HACE EL CONTROL, CONTADO


- **12 citas reancladas** a su frase numerada, literales por construcción.
- **1 respuesta rescatada** en `g3-018`, y **0 problemas sin resolver** en las 20 preguntas.

# Con el modelo de pago terminamos las ejecuciones; acertar, no acertamos más


Preguntas que se quedan sin respuesta  
(sobre el total de cada ejecución)



Tiempo en contestar  
(mediana)



Respuestas correctas en las 13 ejecuciones  
medidas, por sistema y por modelo



CONFIRMADO

Con el modelo gratuito, **9 de cada 20 preguntas se quedaban sin respuesta** y cada una tardaba **cuatro minutos y medio**. Con el de pago: **ninguna perdida de 40 y 22 segundos**.

HIPÓTESIS REFUTADA

Nuestra hipótesis era que el modelo de pago acertaría más. Dos repeticiones **idénticas** — mismo código, misma temperatura, mismas preguntas — dieron **15 aciertos de 20 y 12 de 20**. Con esa variación no se puede afirmar que acierte más, **y no lo afirmamos**.

ERROR QUE COMETIMOS

La primera versión de esta comparación usaba una ejecución hecha con otro código: cambiaban **tres cosas a la vez**, no una. La rehicimos entera. Ahora el protocolo le pregunta a git si `src/` cambió entre las dos, en lugar de fiarse de la etiqueta del fichero.

# Siete ideas razonables que no movieron la métrica

| LO QUE PROBAMOS                                  | QUÉ PASÓ                      |
|--------------------------------------------------|-------------------------------|
| Dar reglas al modelo para elegir qué frase citar | Empeoran las tres variantes   |
| Reescribir la consulta con el modelo             | Igual, y 2,2 s más lento      |
| Filtrar en local antes de llamar al juez         | No bloquea ningún caso        |
| Bajar el esfuerzo de razonamiento del modelo     | El modelo no lo respeta       |
| Ampliar el plazo por pregunta de 300 a 420 s     | No recupera ninguna           |
| Cambiar el modelo que hace de juez               | 20 de 20 veredictos idénticos |
| Pagar por un modelo mejor para acertar más       | Refutado, página 10           |

Un arreglo razonable que no mueve la métrica **es un resultado, no un fracaso**. Los siete quedan registrados con su fecha, su configuración y la métrica antes y después, para no volver a probarlos.

**Lo que sí funcionó**, y está medido en las páginas anteriores: el filtro por metadatos, combinar BM25 con la búsqueda densa, pedir las tres llamadas de una comparativa en un solo mensaje, la regla de universo para los huecos y, sobre todo, la cita por frase numerada.

## EL ERROR QUE MÁS NOS ENSEÑÓ

La primera ablación de proveedor comparaba contra una ejecución hecha con otro código: **tres variables a la vez**. El campo que describe el retrieval coincidía, así que parecía válida. Ahora el protocolo le pregunta a git si `src/` cambió entre las dos ejecuciones, no al fichero.

# Lo que nos llevamos

# 13/20

frente a 7 de 20 del sistema de partida, con un tercio menos de llamadas, la mitad de texto leído y el mismo coste

El techo que queda es nuestro y está localizado: seis preguntas en las que el agente cita una frase válida que no es la que anclamos.

- Las cifras nunca han fallado: el camino exacto aguantó las cuatro ejecuciones con los tres modelos.
- Lo que se rompía era la **trazabilidad**, no la búsqueda.
- Pagar compró llegar al final de la ejecución, no acertar más. Lo comprobamos y lo dijimos.

## LO QUE ENTREGAMOS

- El repositorio con las cuatro herramientas, los tres evaluadores y las funciones `responder()` y `evaluar()`, ejecutables en un clon limpio sin tocar una línea.
- El examen propio en JSONL, los resultados de las trece ejecuciones y el código que genera todas las tablas y todas las figuras de estas páginas.
- Este PDF, que el propio repositorio reconstruye con un comando: las ocho figuras y las dos tablas generadas salen de `resultados/`, no de una hoja de cálculo.
- 453 pruebas en verde y diez cuadernos que se ejecutan de principio a fin sin conexión.

**Y mañana, las diez ciegas.** Preguntas que no ha visto nadie, ejecutadas en clase contra este mismo commit. El protocolo y la tabla de delta, ya publicados, en la página siguiente.

# La tabla del hold-out, publicada vacía el día antes

| FAMILIA              | CIEGAS<br>(24-SEP) | GOLDEN PROPIO<br>(REFERENCIA) | DELTA |
|----------------------|--------------------|-------------------------------|-------|
| Numéricas            | —                  | 7/7                           | —     |
| Extractivas          | —                  | 2/6                           | —     |
| Comparativas         | —                  | 4/7                           | —     |
| Acierto global       | —                  | 13/20 · 65 %                  | —     |
| Citas válidas        | —                  | 12/13                         | —     |
| Llamadas / pregunta  | —                  | 2,20                          | —     |
| Coste USD / pregunta | —                  | 0,0184                        | —     |

Si baja, diremos qué parte de la mejora era general y qué parte era memoria del conjunto con el que iteramos. Eso es un hallazgo, no un suspenso.

## EL PROTOCOLO, CERRADO ANTES DE VER LAS PREGUNTAS

```
python -m agente10k ciegas.jsonl
--etiqueta ciegas --sistema final
```

- Se ejecutan **una sola vez**, con el commit ya entregado. No se itera contra ellas.
- La referencia es la ejecución del golden hecha **con este mismo modelo**, para que el delta no mezcle agente y proveedor.
- Si llegan sin frase de referencia, el recall va a «—» y se reporta solo lo verificable: que la cita exista, que la cifra cuadre con XBRL y las abstenciones.
- Coste estimado **0,18 USD** y unos **4 minutos**.

## LÍMITE DEL MÉTODO

Con veinte preguntas no hay significación estadística: una sola vale cinco puntos porcentuales, y dos repeticiones idénticas del mismo sistema se separaron quince. Solo defendemos diferencias grandes.

# ANEXOS

**15** Cómo medimos: el examen y los evaluadores

**16** Las siete preguntas que seguimos fallando

**17** Las trece ejecuciones completas

**18** Reproducirlo desde un clon limpio

**19** Glosario

# Cómo medimos: el examen y los evaluadores

## EL EXAMEN PROPIO: 20 PREGUNTAS Y 6 HUECOS APARTE

| FAMILIA     | N.º | QUÉ MIDE Y QUÉ EXIGE                                                                             |
|-------------|-----|--------------------------------------------------------------------------------------------------|
| Numérica    | 7   | El control contra XBRL. Cifra que cuadre dentro de la tolerancia                                 |
| Extractiva  | 6   | Búsqueda y trazabilidad. Ancla en una <b>frase literal</b> , no en un identificador de fragmento |
| Comparativa | 7   | Las dos cosas: cifras de los dos ejercicios <b>y</b> frase que lo respalde. El enunciado pedía 6 |
| Hueco       | 6   | Fichero aparte. El dato no existe y la respuesta correcta es decirlo                             |

**Por qué anclamos en la frase y no en el fragmento:** si mejorásemos el troceado del texto, los identificadores cambiarían y el examen dejaría de valer. Con la frase literal, mejorar no penaliza.

**Regla que respetamos:** el examen no se tocó después de ver las respuestas del agente. Cambiarlo tras corregirlo sube la nota y no mejora el sistema.

## LAS CUATRO COMPROBACIONES, Y SE EXIGEN A LA VEZ

|                   |                                                                            |
|-------------------|----------------------------------------------------------------------------|
| <b>a · cita</b>   | Existe el fragmento, el agente lo vio y la frase respalda lo que afirma    |
| <b>b · cifra</b>  | Cuadra con XBRL: <b>0,5 %</b> relativo en USD, <b>medio céntimo</b> en BPA |
| <b>c · camino</b> | Pasó por la herramienta que tocaba, no acertó de casualidad                |
| <b>juez</b>       | Un segundo modelo dice si la respuesta significa lo mismo que la esperada  |

- **La tolerancia no cambia la nota.** Probamos 0 %, 0,1 %, 0,5 % y 1 %: idéntica.
- **Un fallo de infraestructura cuenta como fallo** y no sale del denominador.
- **Cuatro avisos de diagnóstico** (cita corta, fragmento de otra empresa o año, comparativa sin cifra de partida, identificador inexistente): **cero casos**.

# Las siete preguntas que seguimos fallando

| ID     | FAMILIA     | QUÉ OCURRE                                                                                                                 | CITA | CIFRA | CAMINO |
|--------|-------------|----------------------------------------------------------------------------------------------------------------------------|------|-------|--------|
| g3-009 | Extractiva  | Cita una frase del pasaje correcto; nuestro examen ancla en otra del mismo párrafo                                         | OK   | —     | OK     |
| g3-010 | Extractiva  | Mismo caso: frase válida, distinta de la anclada                                                                           | OK   | —     | OK     |
| g3-012 | Extractiva  | Inestable: cambia de veredicto entre repeticiones idénticas                                                                | OK   | —     | OK     |
| g3-013 | Extractiva  | Inestable, mismo patrón                                                                                                    | OK   | —     | OK     |
| g3-015 | Comparativa | Cita exactamente nuestra frase ancla y da las dos cifras buenas; el juez no lo da por equivalente                          | OK   | OK    | OK     |
| g3-018 | Comparativa | El proveedor devolvió un error. Cuenta como fallo del sistema                                                              | NO   | OK    | OK     |
| g3-020 | Comparativa | Detecta el desdoblamiento 10:1 y lo cita, pero se deja la conclusión: no dice que el BPA cae ni que el beneficio neto sube | OK   | OK    | OK     |

Las dos frases de g3-012 , del mismo fragmento y del mismo párrafo.

**Lo que esperábamos:** *"For example, the DOJ and a number of state Attorneys General filed a lawsuit concerning our Search and Search advertising practices..."*

**Lo que citó el agente:** *"We are and may continue to be subject to claims, lawsuits, regulatory and government inquiries and investigations... including competition matters..."*

Las dos responden a la pregunta. La suya es el enunciado general; la nuestra, el ejemplo concreto. Eso es todo lo que separa nuestro 65 % de un 95 %.

DECISIÓN CONSCIENTE

No hemos ampliado el ancla para aprobar estas preguntas. Sería ajustar el examen después de ver las respuestas: sube la nota y no mejora el sistema.

Solo dos son nuestras y no del examen: g3-018 y g3-020 .

# Las trece ejecuciones completas que hemos medido

| EJECUCIÓN                  | MODELO DEL AGENTE         | ACIERTO | NUM. | EXTR. | COMP. | PREGUNTAS PERDIDAS | LLAMADAS /PREG. |
|----------------------------|---------------------------|---------|------|-------|-------|--------------------|-----------------|
| CÓDIGO ENTREGADO           |                           |         |      |       |       |                    |                 |
| baseline                   | gemini-3.8-flash (pago)   | 35 %    | 7/7  | 0/6   | 0/7   | 0                  | 3,30            |
| final                      | gemini-3.8-flash (pago)   | 65 %    | 7/7  | 2/6   | 4/7   | 1                  | 2,20            |
| ABLACIÓN DE PROVEEDOR      |                           |         |      |       |       |                    |                 |
| final, modelo gratuito     | nex-n2.5-pro (gratuito)   | 45 %    | 7/7  | 2/6   | 0/7   | 9                  | 1,55            |
| baseline                   | gemini-3.8-flash (pago)   | 35 %    | 7/7  | 0/6   | 0/7   | 3                  | 2,45            |
| baseline, repetición       | gemini-3.8-flash (pago)   | 30 %    | 6/7  | 0/6   | 0/7   | 5                  | 2,55            |
| final                      | gemini-3.8-flash (pago)   | 75 %    | 7/7  | 4/6   | 4/7   | 0                  | 2,20            |
| final, repetición          | gemini-3.8-flash (pago)   | 60 %    | 7/7  | 2/6   | 3/7   | 0                  | 2,10            |
| RONDAS ANTERIORES          |                           |         |      |       |       |                    |                 |
| baseline                   | nex-n2.5-pro (gratuito)   | 35 %    | 7/7  | 0/6   | 0/7   | 7                  | 2,10            |
| final                      | nex-n2.5-pro (gratuito)   | 60 %    | 7/7  | 4/6   | 1/7   | 6                  | 1,90            |
| final, repetición 1        | nex-n2.5-pro (gratuito)   | 60 %    | 7/7  | 1/6   | 4/7   | 0                  | 2,40            |
| final, repetición 2        | nex-n2.5-pro (gratuito)   | 60 %    | 7/7  | 0/6   | 5/7   | 3                  | 1,90            |
| baseline (histórico)       | ling-3.0-flash (gratuito) | 35 %    | 7/7  | 0/6   | 0/7   | 1                  | 3,30            |
| candidato (sin guardrails) | ling-3.0-flash (gratuito) | 35 %    | 7/7  | 0/6   | 0/7   | 1                  | 3,10            |

**Solo comparamos filas que comparten modelo y código.** El propio programa avisa y no marca ganador si se intentan comparar dos filas con modelos distintos.

Cada medición nueva estrena carpeta: el programa se niega a reutilizar una si no coinciden preguntas, sistema, modelo y configuración.

# Cómo reproducir todo esto desde un clon limpio

## INSTALAR Y COMPROBAR

```
git clone https://github.com/Romequinco/10k-financial-agent
python -m venv .venv
.venv\Scripts\python.exe -m pip install -r requirements.txt
.venv\Scripts\python.exe -m pytest -q          # 453 pruebas
```

## LAS DOS FUNCIONES DEL CONTRATO

```
from agente10k.evaluacion import responder, evaluar
responder("¿Cuál fue el revenue de NVIDIA en 2024?")
evaluar("golden/golden_propio.jsonl")
```

## REGENERAR LA TABLA DE LA PÁGINA 5 Y ESTE PDF

```
from agente10k.evaluacion import tabla_r11
tabla_r11(("baseline_entregado", "final_entregado"))

.venv\Scripts\python.exe informe\construir.py
```

## DÓNDE ESTÁ CADA COSA

- `herramientas.py` — las cuatro herramientas
- `retrieval.py` — filtros, BM25 y combinación
- `agente.py` — el agente y la salida de ocho campos
- `guardrails.py` — tope de llamadas y verificador
- `evaluadores.py` — los tres evaluadores
- `informe/` — genera estas mismas páginas

## FICHA DE LA EJECUCIÓN ENTREGADA

|         |                                                                                                                                                    |
|---------|----------------------------------------------------------------------------------------------------------------------------------------------------|
| Modelo  | google/gemini-3.8-flash, temperatura 0                                                                                                             |
| Commit  | 4e9d60f medido, b02f043 entregado<br>el entregado incluye un cambio posterior en <code>guardrails.py</code> : las cifras son las del commit medido |
| Fecha   | 2026/09/23                                                                                                                                         |
| Coste   | 0,0184 USD por pregunta                                                                                                                            |
| Pruebas | 453, todas en verde                                                                                                                                |

# Glosario

|                                |                                                                                                                                             |                          |                                                                                                                                                      |
|--------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>10-K</b>                    | Informe anual obligatorio de las empresas cotizadas en EE. UU.                                                                              | <b>Búsqueda densa</b>    | Busca por significado. Sirve para encontrar una idea, no una casilla: en una tabla partida en dos, la cabecera con el año se quedó en el otro trozo. |
| <b>XBRL</b>                    | Formato en el que las empresas publican sus cifras etiquetadas una a una. La fuente autorizada de cualquier número.                         | <b>BM25</b>              | Búsqueda clásica por coincidencia de palabras. Complementa a la densa.                                                                               |
| <b>Token</b>                   | Trozo de palabra. El modelo cobra y tarda por cada uno que lee o escribe.                                                                   | <b>Golden set</b>        | Conjunto de preguntas con respuesta conocida que hace de examen.                                                                                     |
| <b>Agente</b>                  | Un modelo que llama a herramientas, ve el resultado y decide el siguiente paso, en vez de responder de una vez.                             | <b>Juez</b>              | El segundo corrector de una redacción: no reescribe la respuesta, solo dice si significa lo mismo que la solución. Y también se equivoca.            |
| <b>Control</b>                 | El segundo lector a la salida del supermercado: no elige lo que metes en el carro, solo impide que salgas sin pasarlo.                      | <b>Camino equivocado</b> | Copiar el resultado del de al lado: hoy apruebas, mañana con otras cifras fallas. Por eso se evalúa el camino, no el número.                         |
| <b>Cita por frase numerada</b> | Cada frase que devuelve la búsqueda lleva un número. El agente responde con el número, no con el texto, y el sistema pega la frase literal. | <b>Recall@5</b>          | Con qué frecuencia la frase correcta aparece entre los cinco resultados de la búsqueda.                                                              |